KLASIFIKASI TUMOR OTAK MENGGUNAKAN CITRA MRI BERBASIS CONVOLUTIONAL NEURAL NETWORK (CNN)

Disusun untuk Memenuhi Tugas Mata Kuliah:

Deep Learning

Dosen Pengampu:

Dr. Wahyudi Setiawan, S.Kom., M.Kom.

Disusun Oleh:

Elfina Lukna Zunaida	240441100013
Nayzila Sukma Laudyandana	240441100037
Tsabita Shafa Aurellia	240441100052
Putri Eka Safira	240441100087

FAKULTAS TEKNIK

PROGRAM STUDI SISTEM INFORMASI

UNIVERSITAS TRUNODJOYO MADURA

2026

BAB 1
PENDAHULUAN

1.1 Latar Belakang

Tumor otak adalah pertumbuhan sel yang tidak normal di dalam atau di sekitar otak. Salah satu cara untuk melihatnya adalah pemeriksaan MRI (Magnetic Resonance Imaging), yang menghasilkan gambar rinci bagian dalam kepala. Membaca gambar MRI membutuhkan dokter spesialis dan waktu yang tidak sedikit, apalagi bila jumlah gambarnya banyak.

Kecerdasan buatan, khususnya Convolutional Neural Network (CNN), banyak dipakai untuk mengenali pola pada gambar. Pada praktikum ini, CNN dilatih untuk mengelompokkan gambar MRI otak ke dalam empat kelas. Selain membangun model, praktikum ini juga menyelidiki pengaruh beberapa pengaturan (pembagian data, augmentasi, optimizer, dan dropout) terhadap kualitas model. Pengaturan tersebut diubah satu per satu secara bertahap, yang disebut progressive ablation study.

Perlu ditegaskan sejak awal: model dalam laporan ini adalah alat belajar dan penelitian, bukan alat diagnosis.

1.2 Tujuan

1. Membangun CNN yang dapat mengklasifikasikan gambar MRI otak ke dalam empat kelas.
2. Menyiapkan dan memeriksa dataset: memuat, mengecek, melakukan preprocessing, dan mengeksplorasi data.
3. Membandingkan pengaruh pembagian data, augmentasi, optimizer, dan dropout terhadap performa model.
4. Mengevaluasi model akhir dengan accuracy, precision, recall, F1-score, dan confusion matrix.
5. Menarik kesimpulan, mencatat keterbatasan, dan menyusun saran perbaikan.

1.3 Ruang Lingkup dan Batasan

- Dataset berisi 7.200 gambar MRI dengan 4 kelas yang seimbang (masing-masing 1.800 gambar).
- Ukuran gambar masukan 128 × 128 piksel, 3 kanal warna (RGB).
- Arsitektur CNN sederhana (4 blok konvolusi), dibuat dari awal tanpa transfer learning.
- Semua konfigurasi dilatih 20 epoch, batch size 32, learning rate 0,0005, dan random seed 42.
- Pelatihan dilakukan di Google Colab tanpa GPU (hanya CPU), sehingga satu epoch memakan sekitar 3 sampai 6 menit.
- Pemilihan konfigurasi terbaik memakai kriteria F1 Macro tertinggi.

BAB II
DASAR TEORI

2.1 Empat Kelas pada Dataset

Tabel 2. Arti sederhana keempat kelas

Kelas	Penjelasan sederhana
glioma	Tumor yang tumbuh dari sel glia, yaitu sel penunjang saraf di otak.
meningioma	Tumor yang tumbuh dari meninges, yaitu selaput pembungkus otak.
pituitary	Tumor pada kelenjar hipofisis (pituitari), kelenjar kecil di dasar otak yang mengatur banyak hormon.
no tumor	Gambar MRI otak yang tidak menunjukkan tumor.

2.2 Convolutional Neural Network (CNN)

CNN adalah jenis jaringan saraf tiruan yang khusus untuk gambar. Bayangkan seseorang memeriksa foto dengan kaca pembesar kecil yang digeser perlahan. Pada awalnya ia hanya mengenali garis dan tepi. Pada tahap berikutnya ia mengenali bentuk, lalu pola yang lebih rumit. CNN bekerja serupa, dengan lapisan-lapisan berikut:

- Convolution (Conv2D): filter kecil berukuran 3 × 3 yang digeser di atas gambar untuk menemukan pola seperti tepi atau tekstur. Jumlah filter (32, 64, 128) menentukan banyaknya jenis pola yang dicari.
- ReLU: fungsi aktivasi yang mengubah nilai negatif menjadi nol, sehingga hanya sinyal penting yang diteruskan.
- MaxPooling 2 × 2: mengambil nilai terbesar pada tiap kotak 2 × 2. Ukuran gambar menjadi setengahnya, tetapi pola yang menonjol tetap terjaga.
- Flatten: meratakan hasil lapisan sebelumnya menjadi satu baris panjang berisi angka.

- Dense: lapisan yang menghubungkan semua angka untuk mengambil keputusan.
- Dropout: mematikan sebagian neuron secara acak saat latihan agar model tidak sekadar menghafal.
- Softmax: mengubah skor akhir menjadi persentase keyakinan untuk keempat kelas, dengan jumlah 100%.

2.3 Pembagian Data: Train, Validation, Test

Data dibagi tiga seperti proses belajar di sekolah. Data latih (train) adalah buku latihan tempat model belajar. Data validasi (validation) adalah ujian percobaan untuk memantau kemajuan belajar. Data uji (test) adalah ujian akhir yang tidak pernah dilihat model saat belajar. Pembagian dilakukan secara stratified, artinya proporsi tiap kelas tetap sama di ketiga bagian.

2.4 Augmentasi Data

Augmentasi menambah variasi gambar latih dengan cara membalik, memutar sedikit, atau memperbesar (zoom) gambar. Tujuannya agar model lebih tahan terhadap perbedaan posisi dan ukuran. Pada praktikum ini augmentasi hanya diterapkan pada data latih, tidak pada data validasi dan uji.

2.5 Epoch, Batch Size, Learning Rate, dan Optimizer

- Epoch: satu putaran penuh model melihat seluruh data latih. Praktikum ini memakai 20 epoch.
- Batch size: banyaknya gambar yang diproses sekaligus sebelum model memperbarui diri (di sini 32).
- Learning rate: ukuran langkah belajar. Terlalu besar membuat model melompat-lompat, terlalu kecil membuat belajar sangat lambat (di sini 0,0005).
- Optimizer: cara model memperbarui dirinya. Adam menyesuaikan langkah secara otomatis dan biasanya cepat. RMSprop juga adaptif.

SGD Momentum melangkah lebih sederhana dengan tambahan "momentum" dan cenderung lebih lambat bila learning rate kecil.

2.6 Overfitting

Overfitting terjadi ketika model terlalu hafal data latih sehingga bagus saat latihan tetapi buruk pada data baru. Tandanya, akurasi latih jauh lebih tinggi daripada akurasi validasi. Dropout dan augmentasi adalah dua cara untuk mencegahnya.

2.7 Metrik Evaluasi

Pada setiap kelas dikenal istilah TP (tebakan benar untuk kelas itu), FP (kelas lain yang salah ditebak sebagai kelas itu), dan FN (gambar kelas itu yang salah ditebak sebagai kelas lain).

Tabel 3. Metrik evaluasi yang dipakai

Metrik	Arti sederhana	Rumus
Accuracy	Dari semua gambar, berapa persen yang ditebak benar.	benar / semua
Precision	Saat model menebak kelas X, seberapa sering tebakannya benar.	TP / (TP + FP)
Recall	Dari semua gambar yang sebenarnya kelas X, berapa persen yang berhasil ditemukan.	TP / (TP + FN)
F1-score	Nilai gabungan precision dan recall.	2 × P × R / (P + R)
Macro average	Rata-rata sederhana dari keempat kelas, sehingga tiap kelas dianggap sama penting.	-

Contoh: pada hasil akhir, model menebak 78 gambar sebagai glioma dan 72 di antaranya memang glioma. Maka precision glioma = 72 / 78 = 0,923.

2.8 Confusion Matrix

Confusion matrix adalah tabel perbandingan kelas sebenarnya (baris) dengan tebakan model (kolom). Angka pada diagonal, dari kiri atas ke kanan bawah, adalah tebakan yang benar. Angka di luar diagonal menunjukkan kelas mana yang tertukar dengan kelas mana.

BAB III
METODOLOGI

3.1 Alur Penelitian

Seluruh pekerjaan ditulis di notebook Google Colab dan dibagi menjadi beberapa bagian kode. Tabel berikut menunjukkan urutan kerja dan letaknya pada notebook.

Tabel 4. Tahapan penelitian dan bagian kode

No	Tahap	Yang dilakukan	Bagian
1	Setup project	Impor library, hubungkan Google Drive, buat folder, atur konfigurasi dan seed.	1
2	Memuat dan cek dataset	Membaca semua gambar, menyamakan nama kelas, mengecek data kosong.	2
3	Preprocessing	Ubah ke RGB, resize 128 × 128, simpan sebagai array.	3
4	Eksplorasi data	Distribusi kelas, contoh gambar, statistik piksel.	4
5	Arsitektur CNN	Membangun model baseline dan diagramnya.	5
6	Pipeline pelatihan	Normalisasi, augmentasi, optimizer, checkpoint, fungsi evaluasi.	6
7	Skenario 1	Membandingkan tiga pembagian data.	7
8	Skenario 2	Membandingkan tanpa dan dengan augmentasi.	8
9	Skenario 3	Membandingkan tiga optimizer.	9

10	Skenario 4	Membandingkan tiga nilai dropout dan menyimpan model champion.	10
11	Evaluasi champion	Metrik, confusion matrix, kurva latihan, visualisasi prediksi.	11-14
12	Rekap dan analisis	Rekap eksperimen, evaluasi final, pembahasan, kesimpulan.	15-18
13	Backup	Mengarsipkan model, grafik, hasil, dan dokumen ke file ZIP (111 file).	19

3.2 Lingkungan dan Konfigurasi

Tabel 5. Konfigurasi umum

Parameter	Nilai
Platform	Google Colab + Google Drive (folder Brain_Tumor_CNN)
Library utama	TensorFlow 2.20.0, scikit-learn, pandas, NumPy, Matplotlib
Perangkat	CPU (GPU tidak terdeteksi)
Ukuran gambar / input CNN	128 × 128 / 128 × 128 × 3
Jumlah kelas	4
Epoch / batch size	20 / 32
Learning rate	0,0005
Loss function	Sparse Categorical Crossentropy
Random seed	42

Struktur folder di Google Drive: dataset, models, grafik, cache, dokumen, hasil, dan checkpoints. Semua gambar grafik yang dibuat notebook tersimpan di folder grafik.

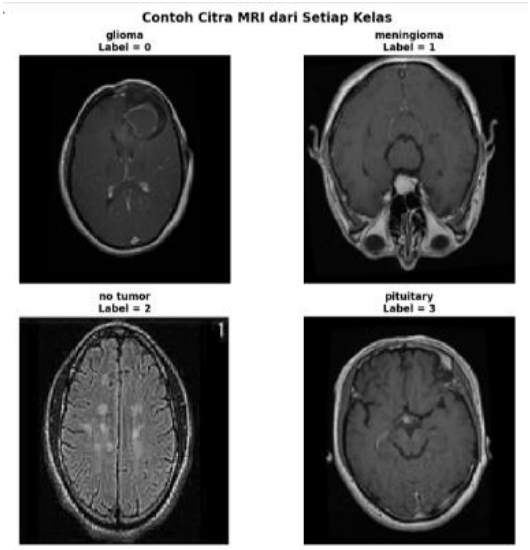
3.3 Dataset

Dataset berada di dua folder utama, yaitu Training dan Testing. Kode membaca gambar dari kedua folder, lalu menyamakan nama kelas (misalnya notumor menjadi no tumor). Hasil pemindaian: 7.200 gambar ditemukan, tidak ada folder yang tidak dikenali, dan tidak ada data kosong (NaN). Seluruh gambar kemudian digabung dan dibagi ulang pada Skenario 1, sehingga pembagian asli Training/Testing tidak dipakai langsung.

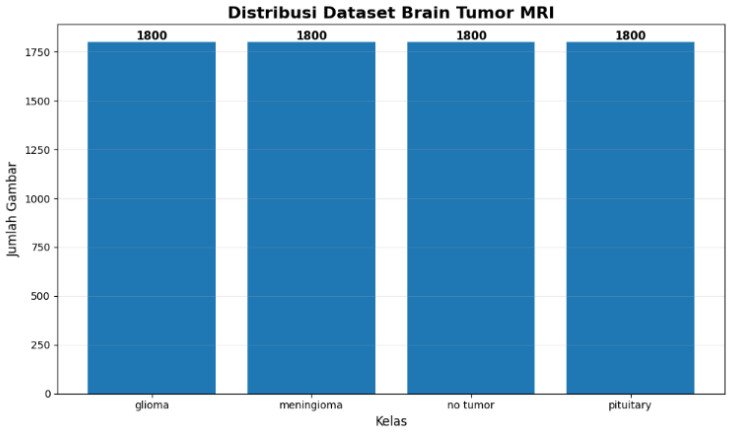
Tabel 6. Distribusi dataset per kelas

Label	Kelas	Jumlah gambar	Persentase
0	glioma	1.800	25,00%
1	meningioma	1.800	25,00%
2	no tumor	1.800	25,00%
3	pituitary	1.800	25,00%
	Total	7.200	100%

Rasio jumlah kelas terbanyak terhadap tersedikit adalah 1,0. Artinya dataset seimbang sempurna, sehingga model tidak cenderung berpihak pada satu kelas karena jumlah datanya.



Gambar 1. Contoh citra MRI dari setiap kelas



Gambar 2. Distribusi jumlah gambar per kelas

3.4 Preprocessing Citra

Preprocessing menyamakan semua gambar agar bisa diproses CNN. Langkahnya untuk setiap gambar:

1. Membuka gambar dari file.
2. Mengubahnya ke format warna RGB (3 kanal).
3. Memperkecil ukuran menjadi 128 × 128 piksel dengan metode LANCZOS.

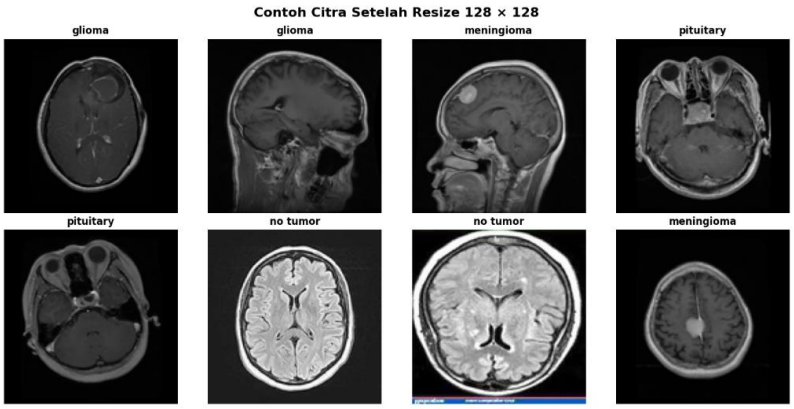
4. Mengubahnya menjadi array angka bertipe uint8 (nilai 0 sampai 255) dan mengecek ukurannya.
5. Menyimpan ke array X berukuran (7200, 128, 128, 3) dan label ke y berukuran (7200).

Hasilnya, 7.200 gambar berhasil diproses dan 0 gagal. Nilai piksel berada pada rentang 0 sampai 255, tanpa NaN maupun nilai tak hingga, dan semua label valid. Array disimpan ke folder cache agar tidak perlu memproses ulang bila Colab terputus. Normalisasi (membagi nilai piksel dengan 255 menjadi 0 sampai 1) dilakukan belakangan, pada saat data masuk ke pipeline TensorFlow.

Tabel 7. Statistik nilai piksel seluruh dataset

Statistik	Nilai
Minimum piksel	0
Maksimum piksel	255
Rata-rata piksel	47,57
Standar deviasi piksel	51,21

Rata-rata piksel 47,57 dari maksimum 255 menunjukkan bahwa gambar cenderung gelap, wajar karena latar belakang citra MRI berwarna hitam.



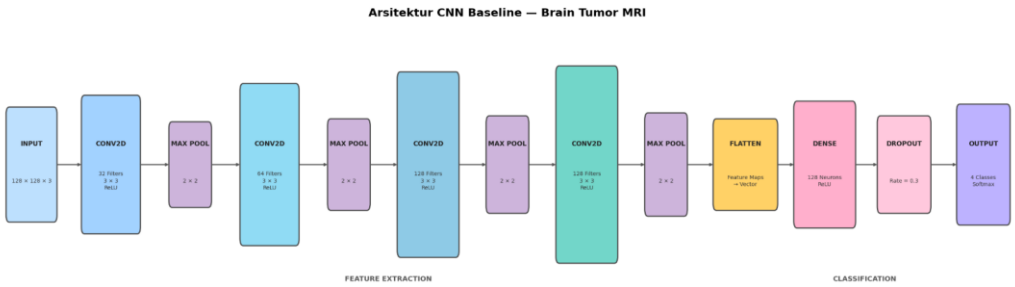
Gambar 3. Contoh citra setelah di-resize menjadi 128 × 128

3.5 Arsitektur CNN Baseline

Model dasar terdiri dari empat blok konvolusi diikuti lapisan pengambil keputusan. Setiap blok MaxPooling membuat ukuran gambar menjadi setengah (128 menjadi 64, 32, 16, lalu 8). Pada akhirnya hasil berukuran 8 × 8 × 128 diratakan menjadi 8.192 angka, lalu diteruskan ke Dense 128 neuron, Dropout, dan lapisan keluaran 4 neuron dengan Softmax.

Tabel 8. Susunan lapisan CNN baseline

No	Lapisan	Tipe	Ukuran keluaran	Parameter
1	conv_block 1	Conv2D (32 filter, 3×3, ReLU)	128 × 128 × 32	896
2	pool_block1	MaxPooling2D (2×2)	64 × 64 × 32	0
3	conv_block 2	Conv2D (64 filter)	64 × 64 × 64	18.496
4	pool_block2	MaxPooling2D	32 × 32 × 64	0
5	conv_block 3	Conv2D (128 filter)	32 × 32 × 128	73.856
6	pool_block3	MaxPooling2D	16 × 16 × 128	0
7	conv_block 4	Conv2D (128 filter)	16 × 16 × 128	147.584
8	pool_block4	MaxPooling2D	8 × 8 × 128	0
9	flatten	Flatten	8.192	0
10	dense_128	Dense (128, ReLU)	128	1.048.704
11	dropout	Dropout (baseline 0,3)	128	0
12	output	Dense (4, Softmax)	4	516
		Total parameter		1.290.052 (4,92 MB)



Gambar 4. Diagram arsitektur CNN baseline

3.6 Pipeline Pelatihan dan Evaluasi

- Normalisasi: nilai piksel dibagi 255 sehingga berada pada rentang 0 sampai 1.
- Augmentasi (bila diaktifkan, hanya pada data latih): flip horizontal, rotasi acak (faktor 0,10, setara maksimal sekitar 36 derajat), dan zoom acak 10%.
- Pipeline data: data diacak (seed 42), dikelompokkan per 32 gambar, dan disiapkan lebih awal (prefetch) agar pelatihan efisien.
- Optimizer yang disiapkan: Adam, RMSprop, dan SGD dengan momentum 0,9, semuanya dengan learning rate 0,0005.
- Checkpoint dan resume: setiap epoch, model, nomor epoch terakhir, dan riwayat loss/accuracy disimpan ke Google Drive. Bila Colab terputus, pelatihan dilanjutkan dari epoch terakhir. Fitur ini terbukti berguna: pelatihan split 90:05:05 sempat berhenti pada epoch 16 dan berhasil dilanjutkan dari epoch 17.
- Evaluasi: model memprediksi data uji, lalu dihitung accuracy, precision macro, recall macro, F1 macro, confusion matrix, dan classification report. Hasilnya disimpan sebagai file CSV.

3.7 Rancangan Eksperimen

Eksperimen dirancang bertahap. Pada tiap skenario hanya satu hal yang diubah, sedangkan pengaturan lain dijaga sama. Pemenang tiap skenario dibawa ke skenario

berikutnya. Semua skenario memakai 20 epoch, batch size 32, dan learning rate 0,0005.

Tabel 9. Rancangan empat skenario

Skenario	Yang diubah	Pilihan	Dijaga tetap
1	Pembagian data	70:15:15, 80:10:10, 90:05:05	Adam, dropout 0,3, tanpa augmentasi
2	Augmentasi	Tanpa, dengan	Split terbaik, Adam, dropout 0,3
3	Optimizer	Adam, RMSprop, SGD Momentum	Split dan augmentasi terbaik, dropout 0,3
4	Dropout	0,0; 0,3; 0,5	Split, augmentasi, dan optimizer terbaik

Kriteria pemilihan adalah F1 Macro tertinggi pada data uji. F1 Macro dipilih, bukan hanya accuracy, karena ia menilai keseimbangan precision dan recall di keempat kelas.

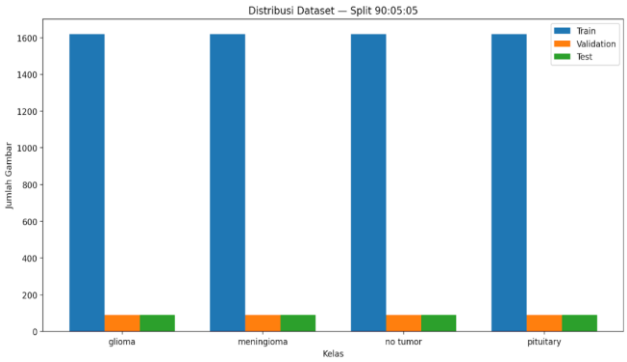
BAB IV
HASIL EKSPERIMEN

4.1 Skenario 1: Pembagian Data

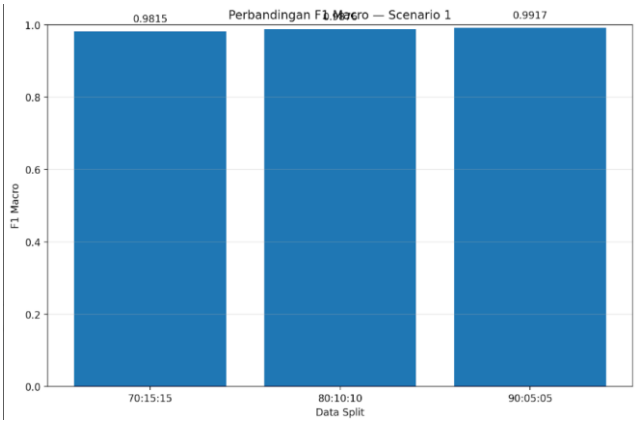
Tiga pembagian data dicoba dengan CNN, Adam, dropout 0,3, dan tanpa augmentasi yang sama. Pembagian bersifat stratified sehingga setiap kelas tetap 25% pada ketiga bagian.

Tabel 10. Hasil Skenario 1 pada data uji

Split	Train	Valid.	Test	Accuracy	Precision	Recall	F1 Macro
70:15:15	5.040	1.080	1.080	0,9815	0,9816	0,9815	0,9815
80:10:10	5.760	720	720	0,9875	0,9879	0,9875	0,9876
90:05:05	6.480	360	360	0,9917	0,9917	0,9917	0,9917



Gambar 5. Distribusi kelas pada split 90:05:05 (train, validation, test)



Gambar 6. Perbandingan F1 Macro tiga pembagian data (Skenario 1)

Semakin besar porsi data latih, skor semakin tinggi: 0,9815 pada 70:15:15, 0,9876 pada 80:10:10, dan 0,9917 pada 90:05:05. Hal ini wajar karena model mendapat lebih banyak contoh untuk belajar. Pada split terbaik, di epoch ke-20 akurasi latih mencapai 0,9915 dan akurasi validasi 0,9889.

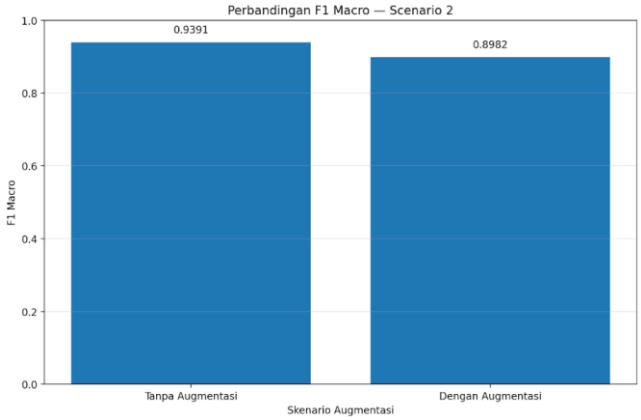
Ada dua catatan. Pertama, ukuran data uji berbeda pada tiap split (1.080, 720, dan 360 gambar), sehingga perbandingannya tidak sepenuhnya setara. Kedua, pada data uji 360 gambar, satu gambar yang salah mengubah akurasi sekitar 0,28 poin persen, sehingga selisih kecil antar-split perlu dibaca hati-hati.

4.2 Skenario 2: Augmentasi

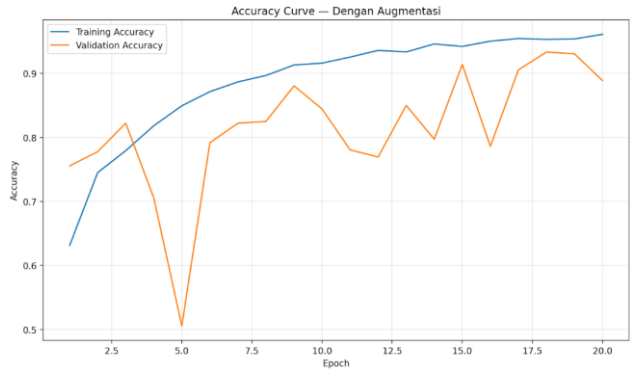
Dengan split 90:05:05, model dilatih dua kali: tanpa dan dengan augmentasi (flip horizontal, rotasi 0,10, zoom 0,10).

Tabel 11. Hasil Skenario 2 pada data uji (split 90:05:05)

Augmentasi	Accuracy	Precision	Recall	F1 Macro
Tanpa augmentasi	0,9389	0,9437	0,9389	0,9391
Dengan augmentasi	0,9000	0,9070	0,9000	0,8982



Gambar 7. Perbandingan F1 Macro tanpa dan dengan augmentasi (Skenario 2)



Gambar 8. Kurva accuracy untuk model dengan augmentasi

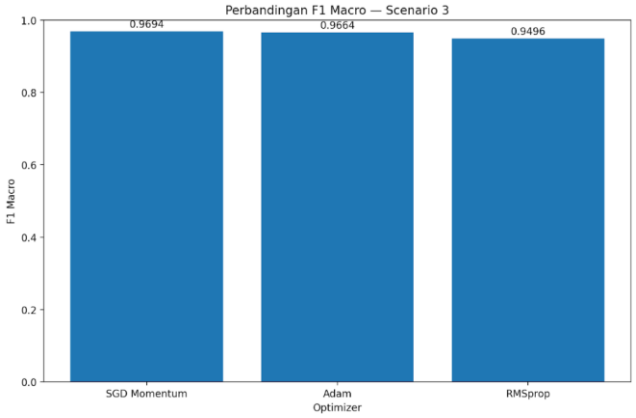
Tanpa augmentasi, skor lebih tinggi (F1 0,9391 berbanding 0,8982). Pada log pelatihan terlihat bahwa model dengan augmentasi belajar kurang stabil: akurasi validasinya turun dari 0,7056 pada epoch 4 menjadi 0,5056 pada epoch 5, lalu naik lagi ke 0,7917 pada epoch 6. Sebaliknya, model tanpa augmentasi naik cukup mulus pada epoch awal (0,7639; 0,8056; 0,8167; 0,8389; 0,8667 pada epoch 1 sampai 5). Dugaan yang masuk akal, augmentasi membuat tugas belajar lebih sulit sehingga membutuhkan lebih banyak epoch daripada 20 untuk menunjukkan manfaatnya.

4.3 Skenario 3: Optimizer

Tiga optimizer dicoba dengan split 90:05:05, tanpa augmentasi, dropout 0,3, dan learning rate 0,0005. Model Adam dimuat dari checkpoint yang sudah selesai 20 epoch, sedangkan RMSprop dan SGD Momentum dilatih baru.

Tabel 12. Hasil Skenario 3 sebagaimana tercatat di notebook

Optimizer	Accuracy	Precision	Recall	F1 Macro
Adam	0,9667	0,9676	0,9667	0,9664
RMSprop (*)	0,9500	0,9503	0,9500	0,9496
SGD Momentum (*)	0,9694	0,9698	0,9694	0,9694



Gambar 9. Perbandingan F1 Macro tiga optimizer (Skenario 3)



Gambar 10. Kurva accuracy training dan validation tiga optimizer

Sesuai catatan, SGD Momentum menempati skor tertinggi (F1 0,9694), disusul Adam (0,9664) dan RMSprop (0,9496). Selisih Adam dan SGD Momentum hanya 0,003 pada accuracy, setara dengan satu gambar dari 360 gambar uji. Log pelatihan RMSprop dan SGD Momentum sama-sama mencetak “Optimizer : Adam”. Penyebabnya ada pada kode: fungsi train_with_resume() melakukan compile ulang model memakai optimizer bawaan (Adam) saat pelatihan baru dimulai, karena parameter optimizer_name tidak diteruskan dari Skenario 3.

Akibatnya, optimizer yang dibuat khusus untuk RMSprop dan SGD Momentum tertimpa.

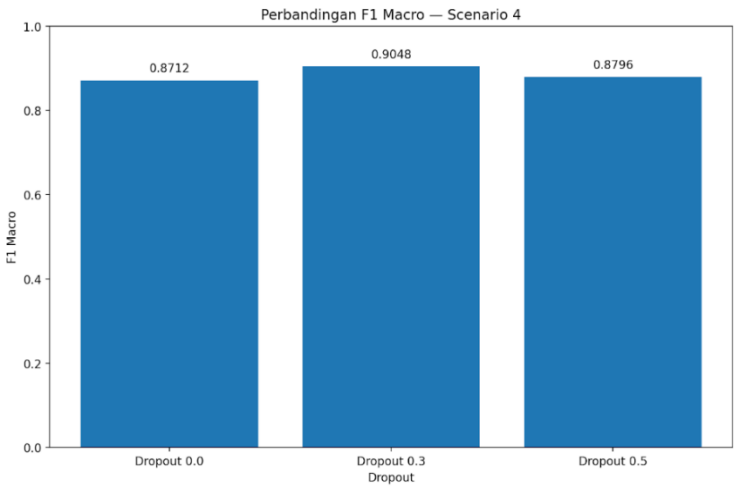
Dengan demikian, ketiga hasil di atas pada dasarnya adalah tiga kali pelatihan Adam dengan bobot awal acak yang berbeda. Rentang skor 0,9496 sampai 0,9694 mencerminkan variasi antar-run, bukan perbedaan kemampuan optimizer. Skenario 3 sebaiknya tidak dibaca sebagai bukti bahwa SGD Momentum lebih baik daripada Adam atau RMSprop, dan perlu diulang setelah kode diperbaiki.

4.4 Skenario 4: Dropout

Pada Skenario 4, optimizer benar-benar SGD Momentum (learning rate 0,0005, momentum 0,9), dengan split 90:05:05 dan tanpa augmentasi. Tiga nilai dropout dibandingkan.

Tabel 13. Hasil Skenario 4 pada data uji

Dropout	Accuracy	Precision	Recall	F1 Macro
0,0	0,8750	0,8865	0,8750	0,8712
0,3	0,9056	0,9070	0,9056	0,9048
0,5	0,8833	0,8922	0,8833	0,8796



Gambar 11. Perbandingan F1 Macro tiga nilai dropout (Skenario 4)

Dropout 0,3 memberi hasil terbaik (F1 0,9048), sedangkan 0,0 terendah (0,8712) dan 0,5 di tengah (0,8796). Pola "nilai sedang paling baik" sesuai teori:

tanpa dropout model mudah menghafal, sedangkan dropout terlalu besar membuat model sulit belajar. Namun selisihnya sekitar 3 poin dan hanya berasal dari satu kali pelatihan, sehingga belum bisa dianggap kesimpulan yang kuat.

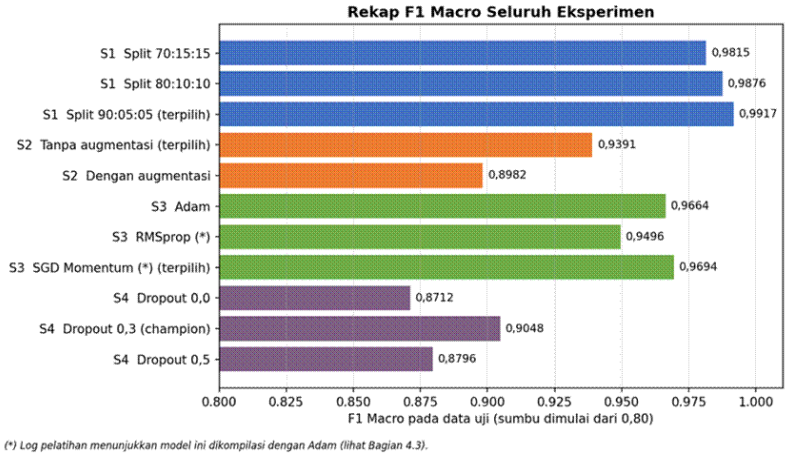
Perhatikan juga bahwa seluruh skor Skenario 4 (0,87 sampai 0,90) lebih rendah daripada skor pada skenario-skenario sebelumnya yang memakai Adam (0,94 sampai 0,99). Pada log terlihat SGD Momentum belajar jauh lebih lambat: akurasi latih epoch pertama hanya sekitar 0,35 untuk dropout 0,0, sedangkan pelatihan Adam sudah sekitar 0,66 pada epoch pertama. Dengan learning rate 0,0005 dan hanya 20 epoch, SGD Momentum kemungkinan besar belum sempat konvergen.

4.5 Rekap Seluruh Eksperimen

Tabel 14. Rekap F1 Macro semua eksperimen

Skenario	Konfigurasi	Jumlah data uji	F1 Macro	Keterangan
1	Split 70:15:15	1.080	0,9815	
1	Split 80:10:10	720	0,9876	
1	Split 90:05:05	360	0,9917	Dipilih
2	Tanpa augmentasi	360	0,9391	Dipilih
2	Dengan augmentasi	360	0,8982	
3	Adam	360	0,9664	Dimuat dari checkpoint
3	RMSprop (*)	360	0,9496	Dikompilasi dengan Adam
3	SGD Momentum (*)	360	0,9694	Dipilih; dikompilasi dengan Adam
4	Dropout 0,0	360	0,8712	

4	Dropout 0,3	360	0,9048	Champion
4	Dropout 0,5	360	0,8796	



Gambar 12. Rekap F1 Macro seluruh eksperimen

BAB V

EVALUASI MODEL AKHIR (CHAMPION)

5.1 Konfigurasi Model

Pengaturan	Nilai
Pembagian data	90:05:05 (6.480 latih, 360 validasi, 360 uji)
Augmentasi	Tidak digunakan
Optimizer	SGD Momentum (learning rate 0,0005, momentum 0,9)
Dropout	0,3
Epoch / batch size	20 / 32
Parameter yang dilatih	1.290.052
File model	models/cnn_champion_final.keras

5.2 Metrik Keseluruhan

Model dievaluasi pada 360 gambar uji (90 per kelas) yang tidak dipakai saat latihan. Hasil yang sama diperoleh pada Bagian 11, 12, dan 16 notebook, sehingga evaluasinya konsisten.

Tabel 15. Metrik model champion pada data uji

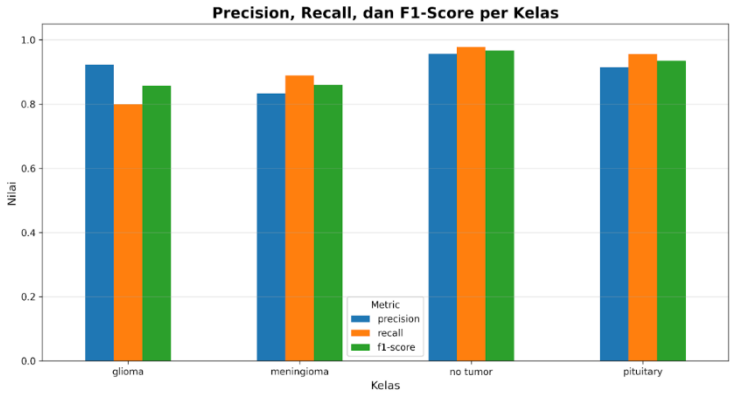
Metrik	Nilai	Persentase
Accuracy	0,9056	90,56%
Precision Macro	0,9070	90,70%
Recall Macro	0,9056	90,56%
F1 Macro	0,9048	90,48%

Dari 360 gambar uji, 326 ditebak benar dan 34 salah. Secara sederhana, sekitar 9 dari 10 gambar dikenali dengan benar.

5.3 Performa per Kelas

Tabel 16. Classification report per kelas

Kelas	Precision	Recall	F1-score	Jumlah data
glioma	0,9231	0,8000	0,8571	90
meningioma	0,8333	0,8889	0,8602	90
no tumor	0,9565	0,9778	0,9670	90
pituitary	0,9149	0,9556	0,9348	90



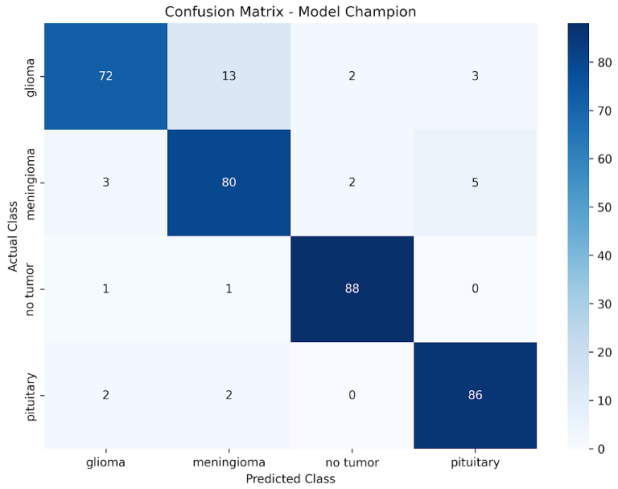
Gambar 13. Precision, recall, dan F1-score per kelas

- no tumor adalah kelas paling mudah (F1 0,967): dari 90 gambar, 88 dikenali benar.
- pituitary cukup baik (F1 0,935), dengan recall tinggi 0,956.
- glioma punya precision tinggi (0,923) tetapi recall terendah (0,800): saat menebak glioma model jarang salah, tetapi banyak glioma yang terlewat (18 dari 90).
- meningioma punya precision terendah (0,833) karena sering menjadi "tempat salah tebak" kelas lain (16 tebakan keliru).

5.4 Confusion Matrix dan Analisis Kesalahan

Tabel 17. Confusion matrix (baris = kelas sebenarnya, kolom = tebakan model)

Sebenarnya \ Tebakan	glioma	meningioma	no tumor	pituitary
glioma	72	13	2	3
meningioma	3	80	2	5
no tumor	1	1	88	0
pituitary	2	2	0	86



Gambar 14. Confusion matrix model champion

Tabel 18. Jumlah tebakan benar dan salah per kelas

Kelas	Benar (TP)	Terlewat (FN)	Salah tebak masuk (FP)	Total sebenarnya
glioma	72	18	6	90
meningioma	80	10	16	90
no tumor	88	2	4	90
pituitary	86	4	8	90

Tabel 19. Pasangan kelas yang paling sering tertukar

Kelas sebenarnya	Ditebak sebagai	Jumlah
glioma	meningioma	13
meningioma	pituitary	5
meningioma	glioma	3
glioma	pituitary	3
glioma	no tumor	2
meningioma	no tumor	2
pituitary	meningioma	2
pituitary	glioma	2
no tumor	meningioma	1
no tumor	glioma	1

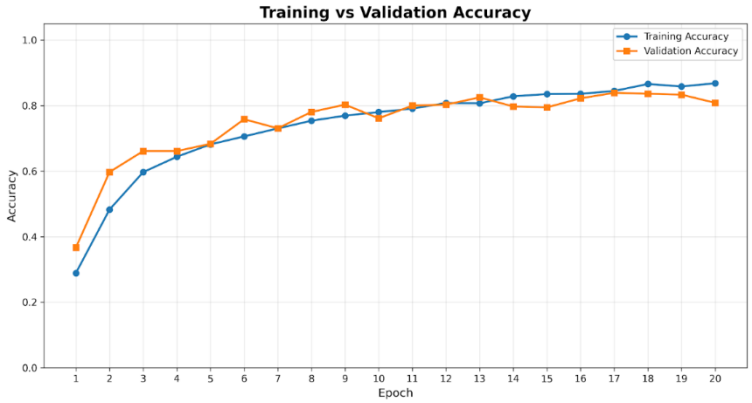
Kesalahan terbesar adalah glioma yang ditebak sebagai meningioma (13 gambar), atau sekitar 72% dari seluruh 18 glioma yang terlewat. Selain itu, 4 gambar bertumor (2 glioma dan 2 meningioma) ditebak sebagai no tumor, atau sekitar 1,5% dari 270 gambar bertumor. Dalam konteks medis, jenis kesalahan ini paling perlu diwaspadai karena tumor yang terlewat bisa menunda penanganan.

5.5 Kurva Pelatihan

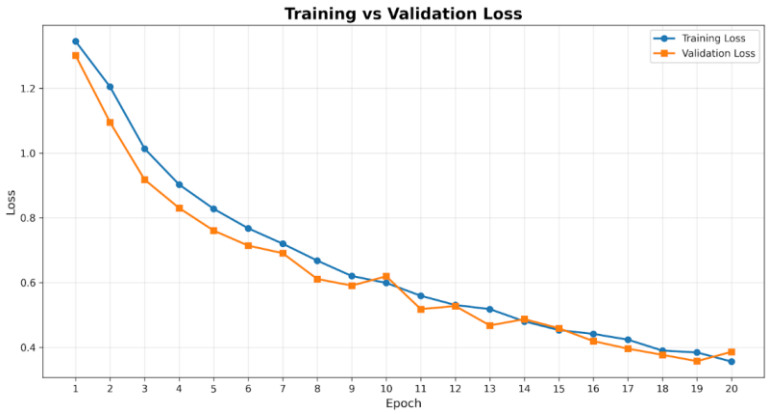
Tabel 20. Angka kunci kurva pelatihan (file riwayat yang terbaca oleh Bagian 13)

Epoch	Akurasi latih	Akurasi validasi	Loss latih	Loss validasi
1	0,2890	0,3667	1,3454	1,3019
10	0,7801	0,7611	0,5991	0,6195
17	0,8446	0,8389	0,4238	0,3960

19	0,8583	0,8333	0,3845	0,3574
20	0,8679	0,8083	0,3561	0,3863



Gambar 14. Kurva accuracy training dan validation



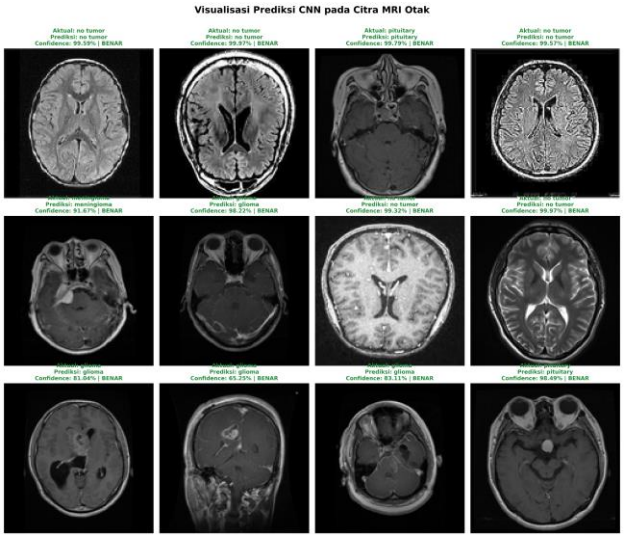
Gambar 15. Kurva loss training dan validation

Kurva menunjukkan loss turun dan akurasi naik secara konsisten selama 20 epoch, dan belum mendatar di akhir. Artinya, model belum sepenuhnya konvergen dan masih bisa membaik bila dilatih lebih lama. Epoch terbaik menurut loss validasi adalah epoch 19 (0,3574) dan menurut akurasi validasi adalah epoch 17 (0,8389). Selisih akurasi latih dan validasi di akhir adalah 0,0596 (sekitar 6 poin), yang oleh kode ditandai sebagai indikasi overfitting ringan. Namun loss validasi masih terkendali, dan data validasi hanya 360 gambar sehingga kurva validasi wajar naik-turun.

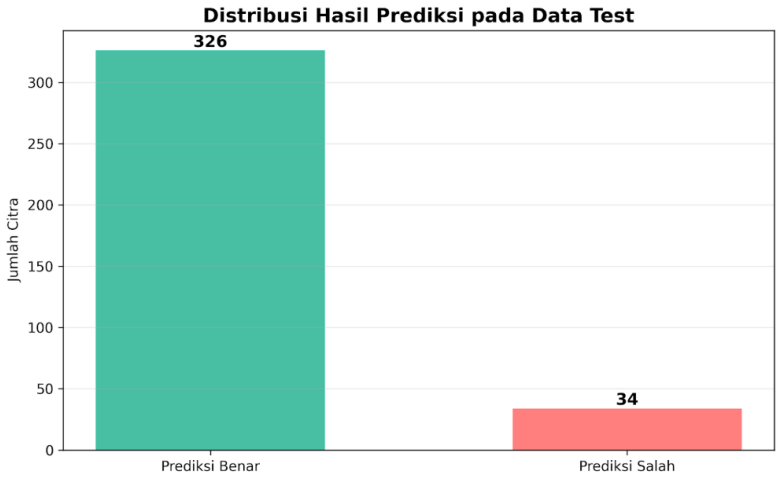
5.6 Visualisasi Prediksi

Bagian 14 menampilkan prediksi model pada contoh citra uji. Dari 360 citra, 326 benar dan 34 salah (90,56%), dengan rata-rata tingkat keyakinan model

88,57%. Pada 15 baris pertama tabel prediksi, 14 benar dan 1 salah: citra indeks 9 adalah glioma tetapi ditebak meningioma dengan keyakinan 69,03%. Ada pula tebakan benar dengan keyakinan rendah, misalnya citra indeks 7 (glioma, 53,90%) dan indeks 11 (pituitary, 52,41%), yang menunjukkan model kadang benar tetapi tidak yakin.



Gambar 16. Contoh hasil prediksi model pada citra MRI uji



Gambar 17. Distribusi hasil prediksi model

Tabel 21. Jumlah sebenarnya dibandingkan jumlah tebakan

Kelas	Sebenarnya	Ditebak model	Selisih
glioma	90	78	-12

meningioma	90	96	+6
no tumor	90	92	+2
pituitary	90	94	+4

Model cenderung terlalu sering menebak meningioma (96 berbanding 90) dan terlalu jarang menebak glioma (78 berbanding 90). Ini konsisten dengan pola kesalahan glioma yang tertukar menjadi meningioma.

BAB VI
PEMBAHASAN

6.1 Makna Hasil

Model CNN sederhana ini mampu mengenali empat kelas dengan akurasi sekitar 90% pada model champion, dan di atas 96% pada beberapa percobaan ber-Adam. Hasil ini menunjukkan bahwa CNN yang kecil (sekitar 1,3 juta parameter) dan dilatih hanya di CPU sudah cukup untuk mempelajari pola penting pada gambar MRI. Kelas no tumor paling mudah dikenali, sedangkan glioma dan meningioma paling sering tertukar.

6.2 Temuan Penting dan Keterbatasan

Pembahasan berikut disusun jujur berdasarkan kode dan log pelatihan, agar pembaca tidak salah menafsirkan hasil.

1. Perbandingan optimizer (Skenario 3) belum murni. Log RMSprop dan SGD Momentum mencetak "Optimizer : Adam" karena train_with_resume() meng-compile ulang dengan Adam. Karena itu pilihan "SGD Momentum" sebagai pemenang tidak didukung bukti yang valid. Seluruh Skenario 4 dan model champion dibangun di atas pilihan ini.
2. Model champion bukan model berskor tertinggi. Champion memperoleh F1 0,9048, sedangkan konfigurasi Adam memperoleh 0,9917 (Skenario 1) dan 0,9664 (Skenario 3). Pada Skenario 4 optimizer benar-benar SGD Momentum dengan learning rate kecil (0,0005), yang belajar lebih lambat sehingga dalam 20 epoch belum konvergen.
3. Ada variasi antar-run. Konfigurasi yang sama (Adam, dropout 0,3, tanpa augmentasi, split 90:05:05) menghasilkan F1 0,9917 (Skenario 1), 0,9391 (Skenario 2), dan 0,9664 (Skenario 3 Adam). Rentangnya sekitar 5 poin, kemungkinan karena bobot awal acak yang berbeda pada tiap run. Akibatnya, selisih kecil antar-pilihan (kurang dari sekitar 3 sampai 5 poin) tidak boleh ditafsirkan berlebihan.

4. Pemilihan konfigurasi memakai data uji. Kriteria F1 Macro dihitung pada data uji, sehingga data uji ikut memengaruhi pemilihan dan skor cenderung sedikit optimistis. Praktik yang lebih baik adalah memilih berdasarkan data validasi dan memakai data uji hanya sekali di akhir. Data uji juga kecil (360 gambar).
5. Kurva pelatihan Bagian 13 berasal dari dropout 0,5, bukan dropout 0,3 milik champion (lihat Bagian 5.5).
6. Kemungkinan kebocoran data (data leakage). Seluruh gambar digabung lalu dibagi acak. Bila dataset berisi beberapa gambar dari pasien yang sama (informasi ini tidak tersedia pada data), gambar yang mirip dapat berada di data latih dan data uji sekaligus, sehingga skor terlihat lebih tinggi daripada kemampuan sebenarnya.
7. Generalisasi belum diuji. Skor berasal dari satu dataset dan tidak menjamin performa yang sama di rumah sakit, alat MRI, atau populasi pasien lain.

6.3 Analisis Kesalahan

Kesalahan terbanyak terjadi antara glioma dan meningioma. Beberapa kemungkinan penyebabnya: pada irisan tertentu kedua jenis tumor dapat tampak mirip; pengecilan gambar menjadi 128 × 128 menghilangkan detail halus; arsitektur yang sederhana; serta pelatihan SGD yang belum konvergen. Dugaan ini belum diuji dan dapat diperiksa lebih lanjut, misalnya dengan melihat langsung gambar-gambar yang salah tebak.

6.4 Catatan Penggunaan

Model ini adalah alat penelitian, bukan pengganti diagnosis tenaga medis. Kesalahan jenis “tumor terlewat” (4 gambar tertebak no tumor) dan “tertukar jenis” dapat berakibat serius bila dipakai dalam praktik klinis. Penggunaan nyata membutuhkan validasi pada data klinis independen dan pengawasan dokter.

BAB 7
KESIMPULAN DAN SARAN

7.1 Kesimpulan

1. Pipeline lengkap berhasil dibangun, mulai dari memuat data, preprocessing, pelatihan dengan checkpoint, sampai evaluasi. Seluruh 7.200 gambar diproses tanpa kegagalan, dengan dataset yang seimbang pada empat kelas.
2. Skenario 1: split 90:05:05 memberi hasil terbaik (F1 Macro 0,9917), dengan tren makin banyak data latih makin tinggi skor.
3. Skenario 2: tanpa augmentasi lebih baik daripada dengan augmentasi (0,9391 berbanding 0,8982) pada batas 20 epoch.
4. Skenario 3: SGD Momentum tercatat tertinggi (0,9694), tetapi perbandingan ini tidak murni karena RMSprop dan SGD Momentum dikompilasi dengan Adam. Skenario ini perlu diulang.
5. Skenario 4: dropout 0,3 terbaik (F1 Macro 0,9048) dan disimpan sebagai model champion.
6. Model champion mencapai accuracy 90,56%, precision macro 90,70%, recall macro 90,56%, dan F1 macro 90,48% pada 360 gambar uji. Kelas terbaik adalah no tumor (F1 0,967) dan tersulit adalah glioma (recall 0,80), dengan kesalahan utama glioma tertebak meningioma (13 gambar).
7. Model champion bukan model berskor tertinggi dalam studi ini. Konfigurasi Adam menunjukkan potensi di atas 96% pada 20 epoch, sedangkan SGD Momentum dengan learning rate 0,0005 belum konvergen.

7.2 Saran

1. Perbaiki pemanggilan train_with_resume() pada Skenario 3 dengan meneruskan optimizer_name=optimizer_label, lalu ulangi Skenario 3 dan Skenario 4.

2. Ulangi setiap eksperimen beberapa kali (misalnya 3 sampai 5 seed berbeda) dan laporkan rata-rata beserta simpangan baku, agar perbedaan antar-pilihan dapat dinilai.
3. Pilih konfigurasi memakai data validasi, dan gunakan data uji hanya sekali pada evaluasi akhir.
4. Untuk SGD Momentum, naikkan learning rate (misalnya 0,01), tambah jumlah epoch, atau gunakan early stopping dan penjadwalan learning rate.
5. Perbaiki Bagian 13 agar membaca file S4_Dropout_Dropout_0_3_history.json, lalu buat ulang grafik kurva pelatihan champion.
6. Coba resolusi gambar lebih besar, batch normalization, atau transfer learning dari model pra-latih untuk memperbaiki pembedaan glioma dan meningioma.
7. Uji model pada data dari sumber lain (idealnya dipisah per pasien), dan gunakan teknik penjelasan seperti Grad-CAM untuk melihat bagian gambar yang menjadi dasar keputusan model.
8. Tetap perlakukan model sebagai alat penelitian, bukan alat diagnosis.